

Modélisation du Risque de Crédit :

Comparaison entre Modèles Structurels et Approches par Machine Learning

Table des matières

1	Introduction	2
2	Les Modèles Structurels du Risque de Crédit	2
2.1	Le modèle de Merton (1974) : la logique économique	2
2.2	Le modèle de Black–Cox (1976) : l’approche par le temps de premier passage	3
2.3	Intuition comparative	3
3	Défis Empiriques : Pénurie de Données et Ingénierie Financière	3
3.1	Réconciliation d’entités et extraction par <i>web scraping</i>	3
3.2	Approximations comptables et leurs biais	4
3.3	La pénurie de données <i>open source</i> : une limite structurelle	4
4	Approches par Machine Learning pour la Prédiction de Défaut	5
4.1	Description du jeu de données	5
4.2	Prétraitement et sélection de variables	5
4.3	Modèles et résultats	6
4.4	Discussion : le piège de l’accuracy et le déséquilibre de classes	7
5	Résultats des Modèles Structurels	7
5.1	Calibration et sorties du modèle	7
5.2	Observations empiriques	8
6	Comparaison des Deux Approches	8
6.1	Performance prédictive	8
6.2	Intérêt pratique en gestion du risque de crédit	9
7	Conclusion	9

1 Introduction

L'évaluation du risque de défaut d'une entreprise est un enjeu central pour les institutions financières et les investisseurs. Historiquement, la littérature financière s'est appuyée sur les modèles dits « structurels », initiés par les travaux fondateurs de **Merton (1974)**, qui modélisent le défaut comme une fonction directe de la structure du capital de l'entreprise.

Cependant, l'application empirique de ces modèles se heurte souvent à des limites opérationnelles sévères, particulièrement en l'absence de bases de données institutionnelles propriétaires telles que Bloomberg ou Compustat. Ce mémoire propose une **double approche** : d'une part, l'implémentation classique des modèles de Merton et de Black–Cox, et d'autre part, l'utilisation d'algorithmes de Machine Learning (Forêt Aléatoire, Gradient Boosting, XGBoost) entraînés sur le jeu de données public *American Bankruptcy*.

L'objectif est d'évaluer dans quelle mesure les approches algorithmiques modernes peuvent surpasser les modèles financiers traditionnels, tant en termes de performance prédictive que de flexibilité face aux données imparfaites. Nous discutons également des défis empiriques considérables liés à la collecte de données en source ouverte, défis qui constituent une contrainte réelle et souvent sous-estimée dans la littérature académique.

2 Les Modèles Structurels du Risque de Crédit

2.1 Le modèle de Merton (1974) : la logique économique

Le modèle de Merton repose sur la théorie de l'évaluation des options de **Black et Scholes (1973)**. L'intuition fondamentale est de considérer les capitaux propres d'une entreprise (V_E) comme une *option d'achat* (call) européenne sur les actifs de l'entreprise (V_A), dont le prix d'exercice correspond à la valeur nominale de la dette (D) et dont l'échéance est la maturité de la dette (T).

À l'échéance T :

- si $V_A > D$: les actionnaires remboursent les créanciers et conservent la différence ;
- si $V_A < D$: les actionnaires exercent leur droit de responsabilité limitée et abandonnent l'entreprise aux créanciers ; l'entreprise est en défaut.

La valeur des capitaux propres s'exprime par la formule de Black–Scholes :

$$V_E = V_A \Phi(d_1) - D e^{-rT} \Phi(d_2) \quad (1)$$

avec

$$d_1 = \frac{\ln(V_A/D) + \left(r + \frac{1}{2}\sigma_A^2\right)T}{\sigma_A\sqrt{T}}, \quad d_2 = d_1 - \sigma_A\sqrt{T}. \quad (2)$$

Une relation supplémentaire, dérivée du lemme d'Itô, relie la volatilité inobservable des actifs (σ_A) à la volatilité observable des capitaux propres (σ_E) :

$$\sigma_E = \frac{V_A}{V_E} \Phi(d_1) \sigma_A. \quad (3)$$

La résolution simultanée des équations (1) et (3) permet de déduire V_A et σ_A , puis de calculer la **Distance au Défaut** (DD) et la **Probabilité de Défaut** (PD) :

$$DD = \frac{\ln(V_A/D) + \left(\mu - \frac{1}{2}\sigma_A^2\right)T}{\sigma_A\sqrt{T}}, \quad PD_{\text{Merton}} = \Phi(-DD) = \Phi(-d_2). \quad (4)$$

2.2 Le modèle de Black–Cox (1976) : l’approche par le temps de premier passage

Une des limites majeures du modèle de Merton est son caractère « européen » : le défaut ne peut survenir qu’à la maturité T . Or, en pratique, une entreprise peut faire faillite à tout moment.

Black et Cox (1976) pallient cette limite en introduisant une *barrière désactivante* (*First Passage Time*). Le défaut survient à l’instant exact τ où la valeur des actifs V_A franchit à la baisse une barrière critique K (généralement liée à la dette à court terme) :

$$\tau = \inf\{t \geq 0 \mid V_A(t) \leq K\}. \quad (5)$$

La probabilité de défaut admet alors la forme fermée suivante :

$$PD_{BC} = \Phi\left(\frac{\ln(K/V_A) - \left(\mu - \frac{1}{2}\sigma_A^2\right)T}{\sigma_A\sqrt{T}}\right) + \left(\frac{K}{V_A}\right)^{\frac{2\mu}{\sigma_A^2}-1} \Phi\left(\frac{\ln(K/V_A) + \left(\mu - \frac{1}{2}\sigma_A^2\right)T}{\sigma_A\sqrt{T}}\right). \quad (6)$$

L’équation (6) intègre la probabilité que la trajectoire des actifs touche la barrière K *avant* l’échéance, rendant le modèle plus conservateur que Merton et mieux adapté à la détection de détresse financière précoce.

2.3 Intuition comparative

TABLE 1 – Comparaison des modèles de Merton et Black–Cox

Critère	Merton (1974)	Black–Cox (1976)
Type d’option	Call européen	Barrière désactivante
Défaut possible	À maturité uniquement	À tout instant
Barrière de défaut	Fixe (égale à D)	Variable (fonction de K)
Conservatisme	Modéré	Plus élevé
Complexité de calibration	Moyenne	Plus élevée
Tolérance aux données imparfaites	Faible	Faible

3 Défis Empiriques : Pénurie de Données et Ingénierie Financière

Si la théorie sous-jacente aux modèles structurels est élégante, sa mise en pratique exige un volume de données structurelles et de marché parfaitement alignées. L’un des obstacles majeurs de cette étude a été la construction d’une base de données robuste en s’appuyant **exclusivement sur des outils *open source***, sans accès aux plateformes institutionnelles telles que Bloomberg ou Compustat.

3.1 Réconciliation d’entités et extraction par *web scraping*

La première difficulté a consisté à relier une base de données légale de faillites (base **LoPucki**) aux données des marchés boursiers. Contrairement aux bases propriétaires, il

n'existe pas d'identifiant universel gratuit reliant le nom d'une entité légale en faillite à son historique de cotation. Il a donc fallu mettre en place une architecture de *web scraping* automatisée — interrogeant les moteurs de recherche via des proxies rotatifs — pour retrouver les tickers boursiers.

Ce défi technique a été exacerbé par le phénomène des **actions radiées** (*delisted*) : les entreprises en défaut voient leur ticker modifié (ajout du suffixe Q sur les marchés OTC), ce qui rend les historiques de prix introuvables via les APIs standard de type Yahoo Finance. Cette problématique de *survivorship bias* est structurelle et limitée aux sources institutionnelles payantes.

3.2 Approximations comptables et leurs biais

Le second défi relève de la structure même des équations de Merton. Pour comparer la valeur marchande (V_E) et la dette (D), les unités doivent être équivalentes. Les données boursières fournissent le prix d'une action unitaire, requérant de multiplier ce prix par le nombre d'actions en circulation (*Shares Outstanding*) pour obtenir la capitalisation totale. Or, ces données historiques sont pratiquement inaccessibles hors des circuits institutionnels.

Pour contourner cette asymétrie d'information, nous avons appliqué l'approximation comptable suivante :

$$N_{\text{actions}} \approx \frac{\text{Capitaux Propres Comptables}_{t_0}}{P_{t_0}} \quad (7)$$

Cette approximation, bien que nécessaire, introduit un **biais systématique** dans deux situations extrêmes :

- **Entreprises en détresse financière** : les capitaux propres comptables sont souvent négatifs, rendant le logarithme népérien de l'équation de Merton indéfini. Nous avons dû forcer ces valeurs à un plancher nominal positif, créant artificiellement un niveau de solvabilité apparent.
- **Déconnecte cours boursier / valeur comptable** : pour des entreprises comme les fintechs ou les entreprises de croissance, le cours boursier peut être un multiple élevé de la valeur comptable. L'approximation (7) sous-estime alors massivement le nombre réel d'actions, faussant V_E .

3.3 La pénurie de données *open source* : une limite structurelle

Au-delà des défis spécifiques mentionnés, cette étude met en lumière une **tension fondamentale** entre la rigueur théorique des modèles structurels et l'accessibilité des données nécessaires à leur implémentation :

- Les modèles structurels nécessitent des séries temporelles de prix d'actions *continues*, des données de déclarations financières précises et synchronisées, ainsi que des historiques d'actions en circulation — données quasi exclusivement disponibles via Bloomberg, Compustat ou Refinitiv.
- En source ouverte, même les APIs les plus permissives (Yahoo Finance, WRDS académique, SEC EDGAR) présentent des lacunes : historiques de tickers archivés incomplets, données des entreprises radiées difficilement accessibles, absence de données standardisées sur les échéances de la dette.
- Par contraste, les modèles de Machine Learning — entraînés sur des ratios comptables standardisés disponibles via SEC EDGAR ou des bases académiques comme

American Bankruptcy — sont structurellement moins dépendants de ces données de marché ad hoc.

Cette asymétrie d'accès aux données constitue en soi un argument fort en faveur des approches ML dans un contexte de ressources limitées.

4 Approches par Machine Learning pour la Prédiction de Défaut

4.1 Description du jeu de données

Le jeu de données utilisé est la base *American Bankruptcy Dataset*, un ensemble public de ratios comptables pour des entreprises américaines sur la période 1999–2018, catégorisées comme **alive** (solvable) ou **failed** (en faillite). Il contient 18 variables financières (notées $X_1, \dots, X_{18}$) couvrant la liquidité, le levier financier, la rentabilité et la taille de l'actif.

Le jeu de données présente un **déséquilibre de classes marqué** : environ 6,8 % des observations correspondent à des entreprises en faillite (**failed** = 0) et 93,2 % à des entreprises solvables (**alive** = 1), ce qui constitue un défi classique en apprentissage automatique appliqué à la détection d'anomalies financières.

4.2 Prétraitement et sélection de variables

Le prétraitement a inclus :

1. **Encodage** : la variable cible **statuslabel** a été transformée en binaire (**alive** → 1, **failed** → 0).
2. **Standardisation** : les variables continues ont été centrées-réduites via **StandardScaler**.
3. **Sélection de variables** : les 10 variables les plus informatives ont été sélectionnées par modèle via importance Gini (Forêt Aléatoire, Gradient Boosting) et valeurs SHAP (XGBoost).
4. **Découpage** : *train/test split* 80/20 avec stratification sur la variable cible.

Les variables sélectionnées par chaque modèle sont résumées dans le tableau suivant :

TABLE 2 – Variables sélectionnées par modèle (Top 10)

Variable	Forêt Aléatoire	Gradient Boosting	XGBoost
X_1	✓	✓	✓
X_2		✓	✓
X_3	✓	✓	✓
X_5		✓	✓
X_7	✓	✓	
X_8	✓		✓
X_{10}	✓		✓
X_{11}		✓	✓
X_{13}	✓	✓	
X_{15}	✓	✓	✓
X_{17}	✓		
X_{18}			✓
year		✓	✓

4.3 Modèles et résultats

Trois algorithmes ont été implémentés et évalués :

Forêt Aléatoire (*Random Forest*)

La Forêt Aléatoire est un ensemble d'arbres de décision entraînés par *bagging*. L'importance des variables est mesurée par l'impureté de Gini. Les résultats obtenus sont :

TABLE 3 – Performance — Forêt Aléatoire

Classe	Précision	Rappel	F1-score	Support
En faillite (0)	0.885	0.051	0.096	1 068
Solvable (1)	0.935	0.999	0.966	14 669
Accuracy globale		93.51 %		
CV Score moyen		93.24 %		

Gradient Boosting (*LightGBM*)

Le Gradient Boosting est un algorithme itératif qui construit des arbres résiduels successifs. Les résultats :

TABLE 4 – Performance — Gradient Boosting

Classe	Précision	Rappel	F1-score	Support
En faillite (0)	<i>cf. notebook</i>	<i>cf. notebook</i>	<i>cf. notebook</i>	1 068
Solvable (1)	<i>cf. notebook</i>	<i>cf. notebook</i>	<i>cf. notebook</i>	14 669
Accuracy globale		~93 %		
CV Score moyen		~93 %		

XGBoost avec analyse SHAP

XGBoost intègre une régularisation L_1/L_2 et utilise les **valeurs SHAP** pour l'interprétabilité. C'est le modèle le plus performant de l'étude :

TABLE 5 – Performance — XGBoost

Classe	Précision	Rappel	F1-score	Support
En faillite (0)	0.737	0.118	0.203	1 068
Solvable (1)	0.939	0.997	0.967	14 669
Accuracy globale		93.73 %		
CV Score moyen		92.98 %		

4.4 Discussion : le piège de l'accuracy et le déséquilibre de classes

Une lecture naïve des résultats pourrait conclure à d'excellentes performances : toutes les méthodes atteignent environ 93 % d'accuracy. Cependant, ce chiffre est **trompeur** dans un contexte de classes déséquilibrées. Un classifieur naïf qui prédit systématiquement « solvable » obtiendrait déjà 93,2 % d'accuracy.

Le véritable indicateur de performance est le **F1-score pour la classe minoritaire (faillite)** : il varie entre 9,6 % (Forêt Aléatoire) et 20,3 % (XGBoost), révélant que les modèles peinent à capturer les entreprises réellement en détresse.

Des techniques de rééchantillonnage telles que **SMOTE** (*Synthetic Minority Over-sampling Technique*) ont été appliquées et ont significativement amélioré le rappel pour la classe faillite, au prix d'une légère baisse de l'accuracy globale — compromis accepté compte tenu de l'asymétrie des coûts d'erreur (type II vs type I) en gestion du risque de crédit.

5 Résultats des Modèles Structurels

5.1 Calibration et sorties du modèle

Les modèles de Merton et Black–Cox ont été calibrés sur un échantillon de 96 entreprises américaines (tickers cotant en bourse et entreprises radiées identifiées par le suffixe Q), à partir de données comptables et de marché reconstituées par *web scraping*. Le tableau 6 présente un extrait représentatif.

TABLE 6 – Extrait des résultats — Modèles structurels (sélection de 10 entreprises)

Ticker	Actifs (V_A)	Dettes (D)	DD	PD_{Merton}	PD_{BC}
ADBE	312.85	317.71	1.261	0.1037	1.000
AFIIQ	290.25	317.83	−0.542	0.7061	1.000
AIV	251.65	122.00	7.639	≈ 0	≈ 0
ALX	124.68	86.76	1.811	0.0351	0.0701
AME	491.82	465.63	3.400	0.0003	0.0009
BBY	666.81	484.00	2.170	0.0150	0.0306
CAL	1 029.73	1 003.21	3.558	0.0002	0.0008
CLH	4 263.08	3 084.55	0.694	0.2439	0.4520
GTX	4 320.76	4 408.00	0.108	0.4570	1.000
TGIC	4.11	1 599.80	−2.567	0.9949	1.000

5.2 Observations empiriques

Plusieurs constats s’imposent à la lecture de ces résultats :

1. **Le modèle de Black–Cox est systématiquement plus conservateur** : sa PD est égale à 1 pour environ 50 % des entreprises de l’échantillon, y compris des entreprises solvables comme ADBE ou GTX. Ce phénomène est lié aux approximations de la barrière K et aux biais d’estimation de σ_A via les données comptables.
2. **La Distance au Défaut comme signal de détresse** : les tickers se terminant par Q (entreprises radiées, probablement en faillite comme AFIIQ, CDVIQ, TGIC) affichent systématiquement une DD négative ou très faible, confirmant la cohérence du signal structurel.
3. **Sensibilité aux valeurs extrêmes** : TGIC présente une valeur d’actifs calculée de \$4.11M pour une dette de \$1 600M, résultat direct des approximations comptables — illustration parfaite du biais introduit par l’équation (7).

6 Comparaison des Deux Approches

6.1 Performance prédictive

La comparaison directe des performances des deux approches se heurte à une difficulté méthodologique : les deux modèles n’ont pas été évalués sur le même jeu de données. Les modèles structurels ont été calibrés sur 96 entreprises individuelles, tandis que les modèles ML ont été évalués sur plus de 15 000 observations paneliques.

Néanmoins, sur les éléments comparables, le tableau 7 synthétise les grands critères :

TABLE 7 – Comparaison synthétique des approches

Critère	Modèles structurels	Machine Learning
Fondement théorique	Fort (Black–Scholes)	Empirique
Données requises	Comptables + marché	Comptables seules
Interprétabilité	Excellente (DD , PD)	Bonne (SHAP)
Adaptabilité aux données manquantes	Très faible	Élevée
Performance sur données déséquilibrées	Pas applicable	Moyenne sans SMOTE
Coût de mise en œuvre	Élevé (scraping, calibration)	Modéré
Applicabilité <i>open source</i>	Très limitée	Bonne
Signal de détresse précoce	Oui (DD)	Partiel (variables X_i)

6.2 Intérêt pratique en gestion du risque de crédit

Modèles structurels. Leur principal avantage réside dans leur **fondement économique explicite** : la Distance au Défaut est un indicateur intuitif et actionnable pour les gestionnaires de risque. Ils permettent également d’évaluer des instruments de crédit (CDS, obligations d’entreprise) en lien direct avec la valeur des actifs. Cependant, leur dépendance aux données de marché de haute qualité les rend peu opérationnels pour les PME, les entreprises non cotées ou dans des contextes d’accès limité aux données.

Machine Learning. Les modèles ML offrent une **flexibilité remarquable** : ils peuvent intégrer des données hétérogènes, traiter les valeurs manquantes et adapter leur sélection de variables. XGBoost, en particulier, bénéficie d’une interprétabilité accrue via les valeurs SHAP, permettant d’identifier les contributions individuelles de chaque variable. Leur limite principale est l’opacité relative du processus de décision et la nécessité d’un jeu d’entraînement historique de qualité.

Approche hybride. La combinaison des deux approches — utiliser le signal DD issu du modèle de Merton comme variable supplémentaire dans un modèle ML — constitue une piste de recherche prometteuse, également explorée dans la littérature récente (cf. *hybrid credit risk models*).

7 Conclusion

Ce mémoire a proposé une double implémentation des modèles structurels de Merton et Black–Cox d’une part, et d’algorithmes de Machine Learning d’autre part, appliqués au problème de la prédiction du risque de défaut d’entreprises américaines.

Les principaux enseignements sont les suivants :

1. **Les modèles structurels restent théoriquement élégants** mais leur mise en œuvre empirique se heurte à des obstacles considérables en l’absence de données institutionnelles : *scraping* de tickers, approximations des actions en circulation, gestion des données extrêmes pour les entreprises insolvables.
2. **Le modèle de Black–Cox tend à sur-estimer le risque de défaut** dans notre échantillon, avec une $PD = 1$ pour environ la moitié des entreprises. Ce résultat

reflète à la fois la sensibilité du modèle aux paramètres non observables et les biais introduits par nos approximations comptables.

3. **Les modèles ML atteignent une accuracy d'environ 93 %** mais peinent à détecter la classe minoritaire (faillite), avec un F1-score ne dépassant pas 20 % sans traitement du déséquilibre. SMOTE améliore sensiblement le rappel de la classe défaut.
4. **XGBoost, associé aux valeurs SHAP**, offre le meilleur compromis entre performance prédictive et interprétabilité parmi les modèles ML testés.
5. **La pénurie de données financières *open source*** est une contrainte réelle et structurelle qui limite la reproductibilité académique des modèles structurels et plaide pour le développement de jeux de données publics standardisés à l'échelle internationale.

En perspective, l'intégration du signal DD comme variable endogène dans un cadre ML hybride, couplée à des données de marché de meilleure qualité, pourrait permettre de combiner les avantages des deux approches et d'améliorer significativement la détection précoce du risque de défaut.

Note : Les graphiques générés (distribution de la Distance au Défaut, comparaison Merton vs Black-Cox, performance des modèles ML) peuvent être intégrés directement dans ce document LaTeX en insérant les commandes `\includegraphics` correspondantes.