

Modélisation du Risque de Crédit :

Comparaison entre Modèles Structurels et Approches par Machine Learning

Table des matières

1	Introduction	2
2	Les Modèles Structurels du Risque de Crédit	2
2.1	Le modèle de Merton (1974) : la logique économique	2
2.2	Le modèle de Black–Cox (1976) : l’approche par le temps de premier passage	3
2.3	Intuition comparative	3
3	Défis Empiriques : Pénurie de Données et Ingénierie Financière	4
3.1	Réconciliation d’entités et extraction par <i>web scraping</i>	4
3.2	Approximation comptable du nombre d’actions	4
3.3	Pénurie de données <i>open source</i>	5
4	Approches par Machine Learning pour la Prédiction de Défaut	5
4.1	Origine et structure du jeu de données	5
4.2	Description des variables	5
4.3	Prétraitement et sélection de variables	6
4.4	Modèles estimés et résultats	7
4.5	Le piège de l’accuracy et le déséquilibre de classes	8
5	Résultats des Modèles Structurels	8
5.1	Calibration et extrait des sorties	8
5.2	Lecture des résultats	9
6	Comparaison des Deux Approches	10
6.1	Performance, interprétation et portée pratique	10
6.2	Apport en gestion du risque de crédit	11
7	Conclusion	11

1 Introduction

L'évaluation du risque de défaut d'une entreprise constitue un enjeu central pour les établissements de crédit, les investisseurs et, plus largement, pour l'ensemble des acteurs exposés au risque de contrepartie. Dans la littérature financière, ce problème a d'abord été abordé par les modèles dits « structurels », initiés par Merton (1974), qui relie explicitement la probabilité de défaut à la structure du capital de l'entreprise et à l'évolution de la valeur de ses actifs.

Cependant, si ces modèles présentent une forte cohérence théorique, leur mise en œuvre empirique suppose l'accès à des données de marché et de bilan riches, propres et synchronisées. En pratique, cette exigence est rarement satisfaite lorsque l'on travaille sans accès à des plateformes institutionnelles comme Bloomberg, Refinitiv ou Compustat. Ce mémoire adopte dès lors une double perspective : d'une part, l'implémentation des modèles structurels de Merton et de Black–Cox ; d'autre part, l'utilisation de méthodes de Machine Learning appliquées à un jeu de données public de faillites d'entreprises américaines.

L'objectif est triple. Il s'agit d'abord de rappeler la logique économique des modèles structurels et leur lien avec la théorie des options. Il s'agit ensuite de mettre en place plusieurs algorithmes de Machine Learning capables de prédire le défaut à partir de variables comptables. Enfin, il s'agit de comparer ces deux familles d'approches au regard de leurs performances, de leur interprétabilité et de leur intérêt pratique dans un contexte de gestion du risque de crédit sous contrainte de données.

Ce travail défend en particulier l'idée suivante : en environnement *open source*, la difficulté principale n'est pas seulement modélisatrice, elle est avant tout **informationnelle**. Les modèles structurels sont pénalisés par leur dépendance à des variables de marché parfois indisponibles ou incomplètes, alors que les approches de Machine Learning peuvent fonctionner à partir d'un socle comptable plus accessible. Cette asymétrie d'accès à l'information constitue un résultat important du mémoire, au-delà même des scores prédictifs obtenus.

2 Les Modèles Structurels du Risque de Crédit

2.1 Le modèle de Merton (1974) : la logique économique

Le modèle de Merton repose sur une intuition fondamentale : les capitaux propres d'une entreprise peuvent être assimilés à une option d'achat européenne sur la valeur de ses actifs. Si l'on note V_A la valeur des actifs, D la valeur faciale de la dette et T l'horizon de maturité, alors les actionnaires conservent l'entreprise à l'échéance uniquement si $V_A > D$. Dans le cas contraire, ils abandonnent l'entreprise aux créanciers ; le défaut survient donc lorsque la valeur des actifs devient insuffisante pour couvrir la dette.

Dans ce cadre, la valeur des fonds propres V_E s'écrit sous la forme Black–Scholes suivante :

$$V_E = V_A \Phi(d_1) - D e^{-rT} \Phi(d_2) \quad (1)$$

avec

$$d_1 = \frac{\ln(V_A/D) + (r + \frac{1}{2}\sigma_A^2)T}{\sigma_A\sqrt{T}}, \quad d_2 = d_1 - \sigma_A\sqrt{T}. \quad (2)$$

Une seconde équation relie la volatilité inobservable des actifs σ_A à la volatilité obser-

vale des capitaux propres σ_E :

$$\sigma_E = \frac{V_A}{V_E} \Phi(d_1) \sigma_A. \quad (3)$$

La résolution simultanée des équations (1) et (3) permet d'obtenir V_A et σ_A , puis de calculer la distance au défaut :

$$DD = \frac{\ln(V_A/D) + \left(\mu - \frac{1}{2}\sigma_A^2\right)T}{\sigma_A\sqrt{T}}, \quad PD_{\text{Merton}} = \Phi(-DD). \quad (4)$$

L'intérêt du modèle est double. D'une part, il fournit une mesure économiquement interprétable du risque de défaut via la *Distance to Default*. D'autre part, il relie directement le risque de crédit à l'information de marché. En revanche, il suppose que le défaut ne puisse se produire qu'à l'échéance, hypothèse restrictive dans de nombreux contextes réels.

2.2 Le modèle de Black–Cox (1976) : l'approche par le temps de premier passage

Le modèle de Black–Cox prolonge Merton en introduisant une barrière de défaut continue. Le défaut n'est plus seulement évalué à maturité : il survient dès que la valeur des actifs franchit à la baisse un seuil critique K , souvent interprété comme une barrière de sécurité liée aux engagements de dette à court terme.

Formellement, si l'on note τ le temps de premier passage, on a :

$$\tau = \inf\{t \geq 0 \mid V_A(t) \leq K\}. \quad (5)$$

La probabilité de défaut du modèle de Black–Cox s'écrit alors :

$$PD_{\text{BC}} = \Phi\left(\frac{\ln(K/V_A) - \left(\mu - \frac{1}{2}\sigma_A^2\right)T}{\sigma_A\sqrt{T}}\right) + \left(\frac{K}{V_A}\right)^{\frac{2\mu}{\sigma_A^2}-1} \Phi\left(\frac{\ln(K/V_A) + \left(\mu - \frac{1}{2}\sigma_A^2\right)T}{\sigma_A\sqrt{T}}\right). \quad (6)$$

Cette extension renforce le réalisme économique du modèle puisque le défaut peut intervenir avant l'échéance. En contrepartie, elle accroît encore les besoins de calibration et rend l'approche particulièrement sensible aux erreurs de mesure sur la dette, la volatilité des actifs et le niveau de barrière retenu.

2.3 Intuition comparative

TABLE 1 – Comparaison des modèles de Merton et Black–Cox

Critère	Merton (1974)	Black–Cox (1976)
Hypothèse de défaut	À maturité uniquement	À tout instant
Nature du modèle	Option européenne	Modèle à barrière
Signal principal	Distance au défaut	Franchissement d'une barrière
Conservatisme	Modéré	Plus élevé
Difficulté de calibration	Élevée	Très élevée
Tolérance aux données imparfaites	Faible	Faible

3 Défis Empiriques : Pénurie de Données et Ingénierie Financière

La principale difficulté du volet structurel n'a pas été d'ordre mathématique, mais d'ordre empirique. Pour passer d'un cadre théorique propre à une implémentation réellement exploitable, il a fallu reconstruire manuellement une base de données mêlant événements de faillite, séries boursières, informations comptables et approximations sur la structure du capital. En l'absence d'outils institutionnels, ce travail a représenté une part substantielle du mémoire.

3.1 Réconciliation d'entités et extraction par *web scraping*

Le premier obstacle a consisté à relier des entités légales issues d'une base de faillites à des entreprises cotées disposant d'un historique de prix. Contrairement aux bases institutionnelles, il n'existe pas de clé universelle gratuite, fiable et directement exploitable pour faire correspondre le nom d'une entreprise en défaut à son ticker de marché. Cette étape a nécessité la mise en place d'une logique de *web scraping* et de recherche assistée pour retrouver les symboles boursiers pertinents.

Cette difficulté est particulièrement forte pour les entreprises radiées. Lorsqu'une société entre en défaut ou sort de cote, son ticker peut changer, notamment avec l'ajout d'un suffixe Q sur certains marchés OTC. Les APIs ouvertes, les moteurs de recherche financiers généralistes et même les historiques disponibles via Yahoo Finance gèrent mal ces transitions. Il en résulte un risque de *survivorship bias* : les entreprises effectivement en détresse sont précisément celles pour lesquelles les données deviennent les plus difficiles à retrouver.

3.2 Approximation comptable du nombre d'actions

Une seconde difficulté a porté sur la conversion du prix unitaire de l'action en valeur totale des capitaux propres de marché. Les modèles structurels nécessitent en effet de comparer une valeur globale des capitaux propres à un stock de dette. Or les données ouvertes fournissent souvent des prix d'actions, mais pas toujours un historique propre et cohérent du nombre d'actions en circulation.

Faute d'accès à une source institutionnelle consolidée, nous avons retenu une approximation comptable de type :

$$N_{\text{actions}} \approx \frac{\text{Capitaux propres comptables}_{t_0}}{P_{t_0}}. \quad (7)$$

Cette approximation était méthodologiquement discutable, mais empiriquement nécessaire. Elle introduit toutefois plusieurs biais majeurs. D'abord, lorsque les capitaux propres comptables sont négatifs, le nombre d'actions estimé peut devenir incohérent, ce qui force à imposer un plancher technique pour éviter de faire exploser les équations. Ensuite, dans les secteurs à forte valorisation boursière relative, l'écart entre valeur comptable et valeur de marché peut être massif ; l'approximation sous-estime alors fortement la capitalisation réelle. Enfin, toute erreur sur cette variable se répercute mécaniquement sur V_E , puis sur V_A , σ_A , DD et finalement la probabilité de défaut.

3.3 Pénurie de données *open source*

Cette étude confirme qu’il existe une pénurie structurelle de données ouvertes pour les modèles structurels du risque de crédit. Les informations théoriquement nécessaires sont connues : dette détaillée par maturité, volatilité boursière, capitalisation complète, historique d’actions en circulation, dates de radiation, barrière de défaut calibrable. Pourtant, dans un cadre *open source*, ces blocs informationnels sont fragmentés entre plusieurs sources hétérogènes et rarement directement alignés.

L’absence de Bloomberg ou d’un outil institutionnel équivalent a donc eu un impact direct sur la qualité de la calibration. Elle n’empêche pas de produire une application empirique, mais elle impose des choix de reconstruction, d’appariement et d’approximation qui fragilisent mécaniquement les résultats. Cet élément mérite d’être mis en évidence, car il explique en partie pourquoi des modèles théoriquement élégants peuvent devenir empiriquement instables lorsqu’ils sont déployés hors d’un environnement professionnel riche en données.

4 Approches par Machine Learning pour la Prédiction de Défaut

4.1 Origine et structure du jeu de données

Le volet Machine Learning repose sur le jeu de données public *US Company Bankruptcy Prediction Dataset*, disponible sur Kaggle. Cette base rassemble des données comptables d’entreprises américaines cotées sur le NYSE et le NASDAQ entre 1999 et 2018. D’après la description du jeu de données, l’échantillon couvre 8 262 entreprises distinctes et 78 682 observations entreprise–année, avec une logique d’étiquetage fondée sur la survenance d’une faillite.

Dans le notebook utilisé pour ce mémoire, la variable cible est notée `statuslabel` et recodée en binaire : `alive=1`, `failed=0`. Les variables explicatives sont principalement comptables et sont notées de X_1 à X_{18} , auxquelles s’ajoute l’année. Ce choix de variables est cohérent avec une logique de prédiction à partir de fondamentaux financiers et tranche nettement avec les besoins informationnels des modèles structurels, davantage dépendants des données de marché.

4.2 Description des variables

Les variables du jeu de données correspondent aux postes comptables suivants :

TABLE 2 – Description des variables du dataset de faillite américain

Variable	Description
X_1	Actifs courants : ensemble des actifs censés être consommés, vendus ou transformés au cours du cycle normal d’exploitation sur l’année à venir.
X_2	Coût des marchandises vendues : coût directement associé à la production ou à la vente des biens et services.
X_3	Dotations aux amortissements et dépréciations : perte de valeur des actifs tangibles et incorporels au cours du temps.

Variable	Description
X_4	EBITDA : résultat avant intérêts, impôts, dépréciation et amortissement, indicateur classique de performance opérationnelle.
X_5	Stocks : valeur comptable des biens détenus pour la production ou la vente.
X_6	Résultat net : profit global après prise en compte de l'ensemble des charges.
X_7	Créances clients : montants dus à l'entreprise pour des ventes déjà réalisées mais non encore encaissées.
X_8	Valeur de marché : dans ce dataset, elle renvoie à la capitalisation boursière de l'entreprise.
X_9	Ventes nettes : chiffre d'affaires après déduction des retours, remises et rabais.
X_{10}	Actif total : ensemble des ressources économiques contrôlées par l'entreprise.
X_{11}	Dettes long terme : dettes financières exigibles au-delà d'un an.
X_{12}	EBIT : résultat avant intérêts et impôts.
X_{13}	Marge brute : profit dégagé après soustraction des coûts directement liés à la production ou à la vente.
X_{14}	Passifs courants : ensemble des dettes de court terme exigibles dans l'année.
X_{15}	Résultats non distribués : profits cumulés conservés dans l'entreprise.
X_{16}	Revenu total : somme des revenus avant déduction des dépenses.
X_{17}	Passif total : totalité des dettes et obligations envers les tiers.
X_{18}	Charges d'exploitation totales : dépenses engagées dans le cadre de l'activité courante.

Ce dictionnaire de variables est important pour l'interprétation économique des modèles. Il montre que l'approche ML ne repose pas sur des indicateurs abstraits, mais sur des grandeurs comptables familières aux analystes crédit. L'interprétabilité du volet algorithmique dépend donc autant des méthodes utilisées que de la compréhension fine de ces variables de bilan et de compte de résultat.

4.3 Prétraitement et sélection de variables

Le notebook met en place une chaîne de traitement relativement standard. La variable cible est recodée, l'échantillon est séparé en ensembles d'entraînement et de test avec stratification, puis les variables sont standardisées lorsque cela est nécessaire. Une sélection de variables est ensuite opérée pour chaque modèle afin de retenir les dix descripteurs les plus informatifs.

Les variables retenues diffèrent légèrement selon les algorithmes, mais certaines dimensions reviennent de manière récurrente : taille de l'entreprise, rentabilité, endettement, stock de résultats accumulés et valeur de marché. Cela renforce l'idée que la faillite peut être approchée par quelques mécanismes économiques robustes, même lorsque la modélisation est purement prédictive.

TABLE 3 – Variables sélectionnées par modèle (Top 10)

Variable	Forêt Aléatoire	Gradient Boosting	XGBoost
X_1	✓	✓	✓
X_2		✓	✓
X_3	✓	✓	✓
X_5		✓	✓
X_6	✓		
X_7	✓	✓	
X_8	✓	✓	✓
X_{10}	✓		✓
X_{11}		✓	✓
X_{13}	✓	✓	
X_{14}	✓		
X_{15}	✓	✓	✓
X_{17}	✓		
X_{18}			✓
year		✓	✓

4.4 Modèles estimés et résultats

Trois algorithmes principaux ont été testés : une Forêt Aléatoire, un modèle de Gradient Boosting de type LightGBM, et XGBoost avec interprétation par valeurs SHAP. Les résultats du notebook montrent des niveaux d'accuracy relativement proches, autour de 93 %, mais des écarts plus marqués sur la capacité à détecter effectivement les entreprises en défaut.

TABLE 4 – Performance — Forêt Aléatoire

Classe	Précision	Rappel	F1-score	Support
En faillite (0)	0.885	0.051	0.096	1 068
Solvable (1)	0.935	0.999	0.966	14 669
Accuracy globale	93.51 %			
CV score moyen	93.24 %			

TABLE 5 – Performance — Gradient Boosting

Classe	Précision	Rappel	F1-score	Support
En faillite (0)	0.697	0.022	0.043	1 044
Solvable (1)	0.935	0.999	0.966	14 693
Accuracy globale	93.45 %			
CV score moyen	93 %			

TABLE 6 – Performance — XGBoost

Classe	Précision	Rappel	F1-score	Support
En faillite (0)	0.737	0.118	0.203	1 068
Solvable (1)	0.939	0.997	0.967	14 669
Accuracy globale	93.73 %			
CV score moyen	92.98 %			

4.5 Le piège de l’accuracy et le déséquilibre de classes

L’un des enseignements majeurs du notebook est que l’accuracy ne constitue pas une mesure suffisante dans un problème de faillite. Le jeu de données est fortement déséquilibré : la classe « solvable » domine l’échantillon. Dans un tel contexte, un modèle peut afficher plus de 93 % d’accuracy tout en restant médiocre sur la classe réellement intéressante, à savoir les entreprises défaillantes.

Les F1-scores de la classe faillite le montrent clairement. Le modèle de Gradient Boosting obtient un rappel très faible, la Forêt Aléatoire améliore un peu la précision mais reste peu sensible, tandis que XGBoost offre le meilleur compromis parmi les modèles testés. Le recours à des techniques comme SMOTE améliore le rappel de la classe minoritaire, mais au prix d’une légère baisse de l’accuracy globale. En gestion du risque de crédit, ce compromis est souvent acceptable, car le coût d’un faux négatif peut être bien supérieur à celui d’un faux positif.




FIGURE 1 – Accuracy des modèles de Machine Learning

5 Résultats des Modèles Structurels

5.1 Calibration et extrait des sorties

Les sorties des modèles structurels sont rassemblées dans le fichier `final_structural_models.csv`. L’échantillon exploitable final comprend 96 entreprises. Les valeurs obtenues doivent être

interprétées avec prudence : elles sont informatives, mais elles reflètent aussi les approximations et contraintes de reconstruction décrites dans la section précédente.

TABLE 7 – Extrait des résultats des modèles structurels

Ticker	Actifs (V_A)	Dette (D)	DD	PD_{Merton}	PD_{BC}
ADBE	312.85	317.71	1.261	0.1037	1.0000
AFIIQ	290.25	317.83	-0.542	0.7061	1.0000
AIV	251.65	122.00	7.639	0.0000	0.0000
ALX	124.68	86.76	1.811	0.0351	0.0701
AME	491.82	465.63	3.400	0.0003	0.0009
BBY	666.81	484.00	2.170	0.0150	0.0306
CAL	1029.73	1003.21	3.558	0.0002	0.0008
CLH	4263.08	3084.55	0.694	0.2439	0.4520
GTX	4320.76	4408.00	0.108	0.4570	1.0000
TGIC	4.11	1599.80	-2.567	0.9949	1.0000

5.2 Lecture des résultats

Plusieurs éléments ressortent. Premièrement, Black–Cox est sensiblement plus conservateur que Merton ; dans une part importante de l'échantillon, la probabilité de défaut atteint 1, ce qui suggère une très forte sensibilité aux hypothèses de barrière et aux valeurs calibrées. Deuxièmement, les tickers associés à des situations de détresse ou de radiation présentent souvent des distances au défaut faibles ou négatives, ce qui va dans le sens de l'intuition économique du modèle.

Troisièmement, certains cas extrêmes illustrent directement les limites de la reconstruction des données. L'exemple de TGIC, avec une dette très importante face à une valeur d'actifs estimée très faible, montre à quel point une approximation sur les actions en circulation ou sur la capitalisation peut produire des probabilités extrêmes. Ces résultats ne doivent donc pas être lus comme une preuve brute de performance, mais comme le produit d'un exercice de calibration empirique sous fortes contraintes informationnelles.




FIGURE 2 – Distribution de la Distance au Défaut sur l'échantillon structurel




FIGURE 3 – Comparaison des probabilités de défaut Merton et Black-Cox

6 Comparaison des Deux Approches

6.1 Performance, interprétation et portée pratique

La comparaison entre modèles structurels et Machine Learning doit être menée avec prudence, car les deux approches ne sont pas calibrées sur les mêmes univers de données. Les modèles structurels sont ici estimés sur un échantillon réduit d'entreprises pour lesquelles une reconstruction de marché a été possible, tandis que les modèles ML sont entraînés sur un large panel standardisé d'observations entreprise-année.

Malgré cette asymétrie, une comparaison qualitative demeure pertinente. Les modèles structurels offrent une interprétation économique directe : la distance au défaut, la logique de responsabilité limitée et la relation actifs-dette sont très lisibles. Les méthodes de Machine Learning, elles, sont plus flexibles, plus faciles à déployer à partir de données comptables ouvertes et plus robustes lorsque les variables de marché sont absentes ou difficiles à reconstituer. En revanche, elles exigent un travail d'évaluation rigoureux pour éviter les illusions de performance liées au déséquilibre des classes.

TABLE 8 – Comparaison synthétique des approches

Critère	Modèles structurels	Machine Learning
Fondement théorique	Très fort	Plus empirique
Données requises	Marché + comptabilité	Comptabilité principalement
Sensibilité aux données manquantes	Très forte	Plus modérée
Interprétabilité	Excellente économiquement	Bonne via SHAP / importances
Facilité d'implémentation en open source	Faible	Bonne
Robustesse au bruit empirique	Faible à moyenne	Moyenne à élevée
Intérêt opérationnel sous contrainte de données	Limité	Élevé

6.2 Apport en gestion du risque de crédit

Dans une logique de gestion du risque, les modèles structurels restent particulièrement utiles lorsqu'on dispose d'un environnement riche en données de marché et que l'on souhaite interpréter économiquement la détérioration de la solvabilité. Ils sont conceptuellement élégants et très cohérents pour relier le défaut à la structure du capital.

Cependant, dans le contexte concret de ce mémoire, l'approche ML apparaît plus opérationnelle. Elle demande moins de reconstruction ad hoc, tolère mieux les imperfections informationnelles et permet d'obtenir des performances prédictives raisonnables sur un large univers d'entreprises. Une voie de recherche prometteuse serait d'ailleurs de combiner les deux approches, par exemple en injectant la distance au défaut comme variable supplémentaire dans un modèle supervisé hybride.

7 Conclusion

Ce mémoire a confronté deux familles d'outils de mesure du risque de défaut : les modèles structurels de Merton et de Black–Cox, d'une part, et plusieurs algorithmes de Machine Learning, d'autre part. La comparaison ne se réduit pas à une opposition entre théorie financière classique et méthodes modernes de prédiction ; elle révèle surtout une opposition entre deux dépendances informationnelles très différentes.

Le principal résultat du travail est le suivant : en théorie, les modèles structurels offrent une lecture très riche du risque de crédit ; en pratique, ils deviennent difficiles à stabiliser lorsqu'on ne dispose pas d'une infrastructure de données institutionnelle. Le recours au scraping des tickers, l'approximation comptable du nombre d'actions en circulation, la rareté des historiques pour les entreprises radiées et la pénurie générale de données de marché ouvertes rendent leur calibration fragile. À l'inverse, les approches de Machine Learning reposant sur des variables comptables standardisées s'avèrent plus adaptées à un cadre de recherche reproductible en environnement *open source*.

Cela ne signifie pas que les modèles structurels doivent être écartés. Au contraire, ils conservent un rôle analytique majeur, notamment pour interpréter la logique économique du

défaut. Mais cette étude montre qu'en présence de contraintes fortes sur l'accès aux données, leur intérêt pratique peut être inférieur à celui d'approches ML pourtant moins ambitieuses sur le plan théorique. C'est précisément dans cet écart entre élégance conceptuelle et faisabilité empirique que se situe l'apport principal de ce mémoire.